Exploration de nouvelles technologies

Projet 2 — Collecter et exploiter des données Web

Pondération : 15 % · **Durée :** 3 semaines
Équipe : 1 à 3 personnes · **Remise :** cours 9, dans Léa

Objectif

Récupérer des données sur un site Web, les enregistrer en **CSV**, puis les nettoyer et les transformer en **documents JSON** pour les exploiter dans **CouchDB**.

Site Web → CSV brut → nettoyage et transformation → JSON → CouchDB

Étapes du projet

1. Choisir un site Web et faire approuver le site et les données par l'enseignant **au plus tard au cours 7**. Vérifier sur quelques pages que l'extraction est possible et que le volume demandé est réaliste.

2. Créer un dépôt **GitHub**, inviter l'enseignant et choisir un outil de webscraping. Chaque membre doit contribuer par des commits significatifs.

3. Extraire les données et les enregistrer dans **un ou plusieurs fichiers CSV bruts obligatoires**, en UTF-8, avec une ligne d'en-têtes. Ces fichiers constituent le résultat de l'extraction : conserver les valeurs recueillies avant leur nettoyage et leur transformation.

4. Définir la structure des documents JSON avant la transformation et l'importation (voir *Modélisation*).

5. À partir des CSV, nettoyer et transformer les données : retirer les doublons, corriger les espaces et les formats, convertir les nombres et traiter les valeurs manquantes. Produire `donnees.json`, un tableau de documents, sans modifier les CSV bruts. Le résultat doit contenir **au moins 2 500 éléments distincts après nettoyage**.

6. Créer une base **CouchDB**, importer le JSON et vérifier le nombre d'éléments, les types et les accents. Conserver le script ou la procédure permettant de reproduire l'importation.

7. Produire **trois requêtes pertinentes** : un filtre multicritère avec projection, un tri avec limite et un regroupement avec calcul. Utiliser Mango pour les deux premières et une vue MapReduce pour la troisième; fournir les index nécessaires.

8. Rédiger un court **rapport en Markdown** et documenter dans le README comment reproduire le travail.

Spécifications des données

Les données doivent :

- provenir d'une **extraction HTML**; une API peut compléter les données, mais ne remplace pas le scraping;
- contenir des champs permettant de filtrer, trier et regrouper les éléments;
- inclure des textes en **français avec accents**, ainsi que des **nombres entiers et décimaux**;
- conserver une URL source ou un identifiant permettant de retrouver leur origine;
- contenir uniquement les **URLs des images**, si des images sont pertinentes.

Respecter les conditions et restrictions du site, espacer les requêtes et ne pas contourner ses protections.

Modélisation

Avant l'importation, déterminer **ce que représente un document** et les questions auxquelles les données doivent répondre.

- Définir les champs, leurs types JSON et un identifiant `_id` unique et stable.
- Regrouper les informations généralement consultées ensemble. Utiliser des objets ou tableaux imbriqués lorsque cela est pertinent; un modèle plat bien justifié est accepté.
- Choisir une convention pour les dates et les valeurs manquantes. Une valeur inconnue ne doit pas devenir automatiquement zéro.

Présenter **deux exemples de documents JSON** et expliquer brièvement les choix retenus.

Remise

Un **ZIP par équipe** à déposer dans **Léa**, contenant :

1. **`rapport.md`**, comprenant :

    - les membres de l’équipe, le site choisi et l’outil d’extraction;
    - le nettoyage effectué et les nombres d’éléments avant/après;
    - la structure des documents (champs et types), deux exemples et la justification du modèle;
    - la méthode d’importation et les vérifications réalisées;
    - les trois requêtes, un extrait des résultats et leur interprétation;
    - le lien GitHub, le nom de la base et un court avis sur les technologies utilisées;
    - la contribution de chaque membre (tâches et pourcentage de participation).
2. Les **CSV bruts** issus de l’extraction et le fichier `donnees.json` nettoyé.
3. Les **scripts, requêtes, index et définition de la vue**, avec un **README** permettant de recréer la base à partir du JSON et de reproduire les résultats.

Le code d’extraction et de transformation doit être disponible dans GitHub. Joindre les images éventuellement utilisées dans le rapport.

Notes

- Inviter **nicolas.payre@cegepsherbrooke.qc.ca** au dépôt GitHub. Les contributions de tous les membres doivent être visibles.
- CouchDB peut être utilisé localement. La remise doit permettre de recréer la base sans refaire l’extraction du site.
- L’IA est autorisée. Mentionner brièvement son utilisation et les vérifications effectuées; chaque membre doit pouvoir expliquer sa contribution.
- Ne déposer aucun mot de passe ou jeton d’accès dans GitHub ou dans la remise.

Évaluation

Critère	Points
Extraction HTML, CSV bruts et qualité des données	25
Modélisation des documents	15
Nettoyage, transformation JSON et importation vérifiée	15
Requêtes et interprétation des résultats	20
Rapport Markdown	10
GitHub, reproductibilité et collaboration	15
Total	**100**